Tên học phần: Học sâu

Lớp: DDU1231

Họ tên: Lê Phương Vy

MSSV: 3123580064

Đường liên kết (Link) Google Docs:

https://docs.google.com/document/d/1xJVl3exQ9GDemKNGlx5CRKgMIxcnS9fbxdzTIU_S3Kg/edit?usp=sharing

BÀI TẬP

Huấn luyện mạng Neuron bằng Batch Gradient Descent

Tóm tắt đề bài:

Tập dữ liệu gồm 3 mẫu:

- Mẫu 1: $x_1 = 1, y_1 = 3$
- Mẫu 2: $x_2 = 2, y_2 = 5$
- Mẫu 3: $x_3 = 3, y_3 = 7$

Learning Rate: $\eta = 0.01$

Khởi tạo: $w^{(0)} = 0, b^{(0)} = 0$

Hàm mất mát (MSE): $L = \frac{1}{3}\sum_{i=1}^{3}(\hat{y}_i - y_i)^2$

PHẦN A: NEURON KHÔNG HÀM KÍCH HOẠT

Mô hình: $\hat{y} = wx + b$

Câu A1: Forward Pass

Công thức: $\widehat{y_i} = wx_i + b$ và $e_i = \widehat{y_i} - y_i$. Với $w = 0, b = 0$:

- Mẫu 1: $\widehat{y_1} = 0 \,.\, 1 + 0 = 0 \Rightarrow e_1 = 0 - 3 = -3 \Rightarrow e_1^2 = 9$
- Mẫu 2: $\widehat{y_2} = 0 \,.\, 2 + 0 = 0 \Rightarrow e_2 = 0 - 5 = -5 \Rightarrow e_2^2 = 25$
- Mẫu 3: $\widehat{y_3} = 0 \,.\, 3 + 0 = 0 \Rightarrow e_3 = 0 - 7 = -7 \Rightarrow e_3^2 = 49$

Bảng kết quả A1:

i	x_i	y_i	w	b	$\widehat{y_i}$	e_i	e_i^2
1	1	3	0	0	0	-3	9
2	2	5	0	0	0	-5	25
3	3	7	0	0	0	-7	49

Câu A2: Tính Loss

- Tổng sai số bình phương: $\sum_{i=1}^{3} e_i^2 = 9 + 25 + 49 = 83$
- MSE = $\frac{1}{3}\sum_{i=1}^{3} e_i^2 = \frac{83}{3} \approx 27.67$

Bảng kết quả A2:

$\sum_{i=1}^{3} e_i^2$	MSE
83	27.67

Câu A3: Tính Gradient (Batch GD)

Công thức:

$$\frac{\partial L}{\partial w} = \frac{2}{3}\sum_{i=1}^{3} e_i x_i \ , \frac{\partial L}{\partial b} = \frac{2}{3}\sum_{i=1}^{3} e_i$$

Tính các thành phần $e_i x_i$:

- $i = 1$: $e_1 x_1 = (-3).1 = -3$
- $i = 2$: $e_2 x_2 = (-5).2 = -10$
- $i = 3$: $e_3 x_3 = (-7).3 = -21$

Bảng tính A3:

i	e_i	x_i	$e_i x_i$
1	-3	1	-3
2	-5	2	-10

3	-7	3	-21
Tổng	$\sum_{i=1}^{3} e_i = -15$		$\sum_{i=1}^{3} e_i x_i = -34$

Tính đạo hàm:

- $\frac{\partial L}{\partial w} = \frac{2}{3}.(-34) = -\frac{68}{3} \approx -22.67$
- $\frac{\partial L}{\partial b} = \frac{2}{3}.(-15) = -10$

Câu A4: Cập nhật tham số

Công thức:

$$w^{(1)} = w^{(0)} - \eta \frac{\partial L}{\partial w}, b^{(1)} = b^{(0)} - \eta \frac{\partial L}{\partial b}$$

- $w^{(1)} = 0 - 0.01.(-22.67) = 0.2267$
- $b^{(1)} = 0 - 0.01.(-10) = 0.10$

Bảng kết quả A4:

Tham số	Giá trị cũ	Gradient	η	Giá trị mới
w	0	-22.67	0.01	0.2267
b	0	-10.00	0.01	0.1000

PHẦN B: NEURON CÓ HÀM KÍCH HOẠT SIGMOID

Mô hình:

$$z = wx + b, \hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}$$

Với $w = 0, b = 0 \Rightarrow z_i = 0.x_i + 0 = 0$ cho mọi i. Do đó:

$$\widehat{y_i} = \sigma(0) = \frac{1}{1+e^0} = 0.5$$

Câu B1: Forward pass

Tính sai số $e_i = \widehat{y_i} - y_i$:

- $i = 1: e_1 = 0.5 - 3 = -2.5$

- $i = 2: e_2 = 0.5 - 5 = -4.5$
- $i = 3: e_3 = 0.5 - 7 = -6.5$

Bảng kết quả B1:

i	x_i	y_i	z_i	$\widehat{y_i}$	e_i
1	1	3	0	0.5	-2.5
2	2	5	0	0.5	-4.5
3	3	7	0	0.5	-6.5

Câu B2: Đạo hàm Sigmoid

Cho hàm Sigmoid:

$$\sigma(z) = \frac{1}{1+e^{-z}} = (1+e^{-z})^{-1}$$

Lấy đạo hàm hai vế theo z**:**

$$\sigma'^{(z)} = -1 \cdot (1+e^{-z})^{-2} \cdot (1+e^{-z})' = -1 \cdot (1+e^{-z})^{-2} \cdot (-e^{-z}) = \frac{e^{-z}}{(1+e^{-z})^2}$$

$$\sigma'(z) = \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}} = \frac{1}{1+e^{-z}} . \frac{(1+e^{-z})-1}{1+e^{-z}}$$

$$= \frac{1}{1+e^{-z}} . \left(\frac{1+e^{-z}}{1+e^{-z}} - \frac{1}{1+e^{-z}}\right)$$

$$= \frac{1}{1+e^{-z}} . \left(1 - \frac{1}{1+e^{-z}}\right)$$

Thay $\sigma(z) = \frac{1}{1+e^{-z}}$ vào biểu thức trên:

$$\sigma'(z) = \sigma(z)(1-\sigma(z))$$ (ĐPCM)

Câu B3: Tính Gradient bằng chain rule

Biểu thức Gradient:

$$\frac{\partial L}{\partial w} = \frac{2}{3}\sum_{i=1}^{3} e_i \widehat{y_i}(1-\widehat{y_i})x_i$$

$$\frac{\partial L}{\partial b} = \frac{2}{3}\sum_{i=1}^{3} e_i \widehat{y_i}(1-\widehat{y_i})$$

Với $\widehat{y_i} = 0.5 \Rightarrow \widehat{y_i}(1-\widehat{y_i}) = 0.5(1-0.5) = 0.25$:

- $i = 1$: $e_1\widehat{y_1}(1-\widehat{y_1}) = -2.5 \times 0.25 = -0.625$; tích với x_1 : $-0.625 \times 1 = -0.625$
- $i = 2$: $e_2\widehat{y_2}(1-\widehat{y_2}) = -4.5 \times 0.25 = -1.125$; tích với x_2 : $-1.125 \times 1 = -2.250$
- $i = 3$: $e_3\widehat{y_3}(1-\widehat{y_3}) = -6.5 \times 0.25 = -1.625$; tích với x_3 : $-1.625 \times 3 = -4.875$

Bảng tính B3:

i	e_i	$\widehat{y_i}(1-\widehat{y_i})$	$e_i\widehat{y_i}(1-\widehat{y_i})$	$e_i\widehat{y_i}(1-\widehat{y_i})x_i$
1	-2.5	0.25	-0.625	-0.625
2	-4.5	0.25	-1.125	-2.250
3	-6.5	0.25	-1.625	-4.875
Tổng			$\sum = -3.375$	$\sum = -7.750$

Tính Gradient:

- $\frac{\partial L}{\partial w} = \frac{2}{3}.(-7.750) = -5.1667$
- $\frac{\partial L}{\partial b} = \frac{2}{3}.(-3.375) = -2.2500$

Câu B4: Cập nhật tham số

- $w^{(1)} = 0 - 0.01 \times (-5.1667) = 0.0517$
- $\mathrm{b}^{(1)} = 0 - 0.01 \times (-2.2500) = 0.0225$

Bảng kết quả B4:

Tham số	Giá trị cũ	Gradient	η	Giá trị mới
w	0	-5.1667	0.01	0.0517
b	0	-2.2500	0.01	0.0225

PHẦN C: CÂU HỎI NHẬN XÉT

1. So sánh biểu thức Gradient của hai trường hợp
   - **Trường hợp 1:** Neuron không dùng hàm kích hoạt (Mô hình tuyến tính)

     $\frac{\partial L}{\partial w} = \frac{2}{3}\sum_{i=1}^{3} e_i x_i$ và $\frac{\partial L}{\partial b} = \frac{2}{3}\sum_{i=1}^{3} e_i$

     Trong đó $e_i = \widehat{y_i} - y_i$ và $\widehat{y_i} = wx_i + b$
   - **Trường hợp 2:** Neuron sử dụng hàm kích hoạt Sigmoid

     $\frac{\partial L}{\partial w} = \frac{2}{3}\sum_{i=1}^{3} e_i \widehat{y_i}(1-\widehat{y_i})x_i$ và $\frac{\partial L}{\partial b} = \frac{2}{3}\sum_{i=1}^{3} e_i \widehat{y_i}(1-\widehat{y_i})$

     Trong đó: $e_i = \widehat{y_i} - y_i$ và $\widehat{y_i} = \sigma(z) = \sigma(wx_i + b)$
   - **Điểm khác biệt chính:** Biểu thức Gradient của mô hình Sigmoid có thêm thừa số $\widehat{y_i}(1-\widehat{y_i})$, đây chính là đạo hàm của Sigmoid $\sigma'(z_i)$ thu được khi áp dụng quy tắc chuỗi (Chain Rule)
2. Vì sao Gradient trong trường hợp Sigmoid nhỏ hơn?

   Gradient trong trường hợp Sigmoid nhỏ hơn rõ rệt vì các lí do sau:
   - **Giới hạn của đạo hàm Sigmoid:** Hàm đạo hàm Sigmoid có dạng $\sigma'(z) = \sigma(z)(1-\sigma(z))$. Vì $0 < \sigma(z) < 1$, giá trị lớn nhất mà đạo hàm này có thể đạt được là 0.25 (tại $z = 0$)
   - **Tác động nhân làm giảm giá trị:** Trong biểu thức Gradient của Sigmoid, toàn bộ đại lượng $(e_i x_i)$ đều bị nhân thêm với thừa số $\widehat{y_i}(1-\widehat{y_i}) \leq 0.25$. Do đó, giá trị tuyệt đối của Gradient bị thu nhỏ đi ít nhất là 4 lần so với mô hình không dùng hàm kích hoạt.
3. Trường hợp nào hội tụ nhanh hơn? Giải thích?
   - Trường hợp Neuron không dùng hàm kích hoạt hội tụ nhanh hơn
   - Giải thích:
     - **Độ lớn của bước cập nhật:** Do Gradient của mô hình không dùng hàm kích hoạt lớn hơn hẳn, lượng thay đổi tham số ở mỗi vòng lặp $\Delta w = -\eta \frac{\partial L}{\partial w}$ sẽ lớn hơn, giúp mô hình tiến về vùng tối ưu nhanh hơn với cùng một Learning rate $\eta = 0.01$

- **Hiện tượng triệt tiêu Gradient (Vanishing Gradient):** Mô hình Sigmoid dễ rơi vào vùng triệt tiêu Gradient khi $|z|$ lớn, làm cho đạo hàm $\sigma'(z) \approx 0$, dẫn đến tham số hầu như không được cập nhật

4. Dữ liệu bài toán này có phù hợp với Sigmoid không? Vì sao?
   - Dữ liệu bài toán không phù hợp với hàm Sigmoid
   - Vì sao?
     - **Bất đồng về miền giá trị (Range Mismatch):** Đầu ra của hàm Sigmoid bị chặn chặt trong khoảng (0,1). Trong khi đó, các nhãn mục tiêu trong tập dữ liệu là $y \in \{3,5,7\}$ (đều lớn hơn 1). Mô hình dùng Sigmoid không bao giờ có thể dự đoán được các giá trị $y > 1$, dẫn đến sai số luôn luôn lớn hơn dù có huấn luyện bao nhiêu epoch
     - **Sai lệch loại bài toán:** Hàm Sigmoid chỉ thích hợp làm hàm kích hoạt ở lớp đầu ra cho bài toán Phân loại nhị phân (Binary Classification) để đưa ra dự đoán về dạng xác suất. Bài toán này là bài toán Hồi quy (Regression) tìm hàm tuyến tính $y = 2x + 1$ do đó không được dùng hàm Sigmoid ở đầu ra